以半導體法說會逐字稿 建立投資組合

建置流程

文本蒐集一 文本前處理一 狀態分類(Label)一 費半30企業 詞性還原、斷詞 Good/Bad/Neutral

統計檢定— 將詞按分類檢視合理性

建構機器學習預測模型

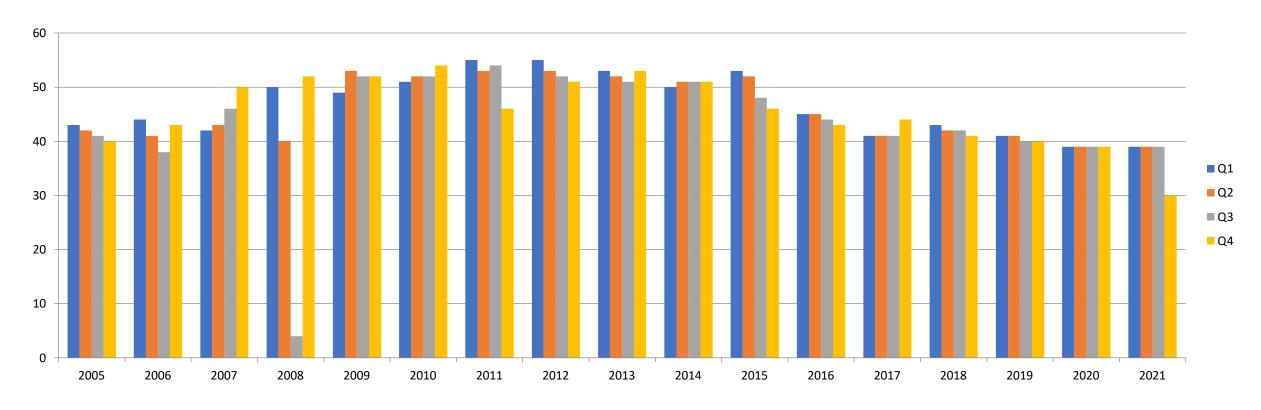
投資組合回測

資料 - 歷史費半企業

• 期間: 2005/Q3-2021/Q4

• 總公司數:66

• 總文本數:3081



資料 - 歷史費半企業

- 上游公司:INFN、INTC、MU、NSM、NXPI、ON、QRVO、STM、SWKS、TXN、ADI、ALTR、AMD、ARMH、ATHR、ATML、AVGO、BRCM、CAVM、CRUS、CY、FSL、HITT、IDCC、IDTI、IFNNY、IPHI、LLTC、LSCC、MCHP、MLNX、MPWR、MRVL、MSCC、MSI、MXIM、NETL、NVDA、NVLS、POWI、QCOM、RFMD、SIMO、SLAB、SMTC、SNDK、SPRD、XLNX
- 中游公司:AMAT、ASML、BRKS、CCMP、CREE、ENTG、KLAC、LRCX、LSI、MKSI、RBCN、SUNEQ、TSM、VECO、IPGP、AZTA、IIVI、WOLF
- 下游公司:TER、AMKR

文本蒐集一爬蟲(Web Crawler)

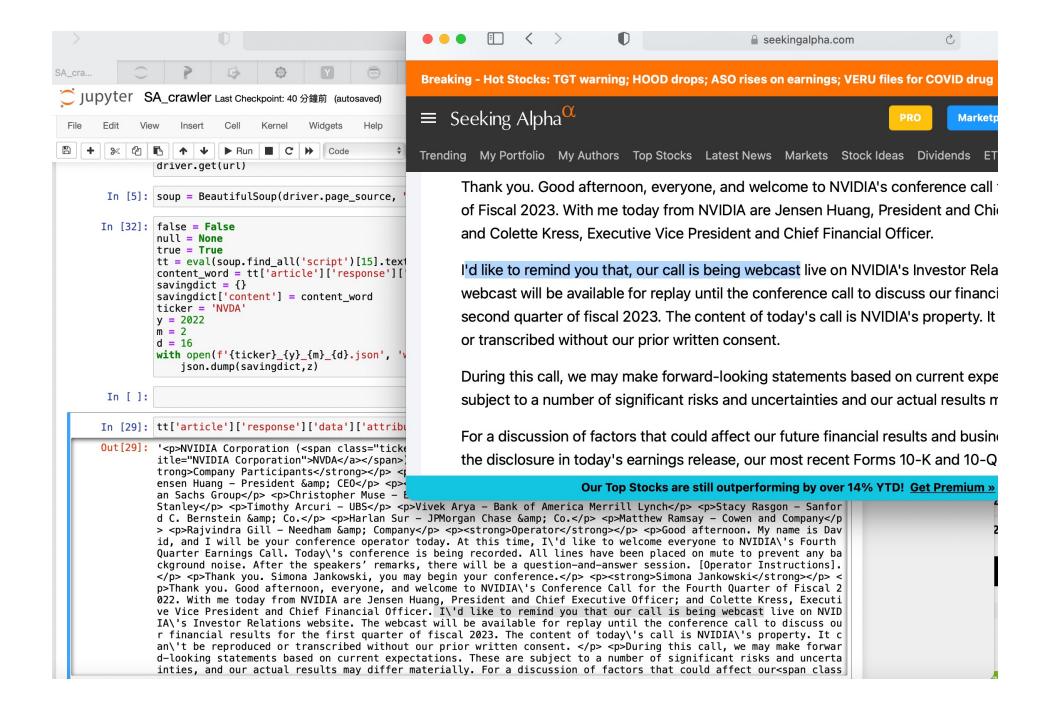
• 資料來源: SeekingAlpha、Bloomberg資料庫

• 使用套件: python Selenium + Requests

• 方法:因若需查閱一年以前之法說會文本需使用付費會員,故不能直接透過request方式分析前端網頁代碼,而需要使用Selenium開啟虛擬瀏覽器後,登入會員,分析網頁格式才能 取得需要之文本內容。取得內容後需進行文本處理,分辨發言者

與發言內容, 存入設定之格式。

	A	В	С	D	Е	F
1	Speaker	Position	Content	Order		
2	Jeff Su	Director of Investor Relations	(Foreign Lan	1		
3	Wendell Hua	Chief Financial Officer	Thank you, J	2		
4	C.C. Wei	Chief Executive Officer	Thank you. V	3		
5	Wendell Hua	Chief Financial Officer	Thank you, (4		
6	Jeff Su	Director of Investor Relations	Thank you, V	5		
7	Questions An	Questions And Answers	Questions An	Questions And A	nswers	
8	Operator	Operator	The first foll	6		
9	Gokul Hariha	Analyst	Congratulation	7		
10	Jeff Su	Director of Investor Relations	Okay. Gokul	8		
11	Wendell Hua	Chief Financial Officer	Yes. Gokul,	9		
12	Jeff Su	Director of Investor Relations	Okay. And tl	10		
13	C.C. Wei	Chief Executive Officer	Well, let me	11		
14	Jeff Su	Director of Investor Relations	Okay. Thank	12		
15	Operator	Operator	Next one we	13		
16	Randy Abran	Analyst	Okay. Yes. 7	14		
17	Jeff Su	Director of Investor Relations	Okay. Randy	15		
18	Wendell Huar	Chief Financial Officer	Okay. Randy	16		
19	Randv Ahram	Analyst	Okav Great	17		



文本前處理一詞性還原(Lemmatization)

英文單字會因時態、單複數不同而變化,若不處理會造成文字探勘研究的偏誤,例如 the performance looks good 和 the performance is better than last year 兩句話的 good 和 better 是比較級關係,卻會被當成兩個不同的單字

- 使用套件: NLTK + Stanza(美國 Stanford大學開發之語言處理套件)
 - 以 it's better than before 為例
 - NLTK: it 's good than before
 - Stanza: it be better than before
- Stanza 無法處理形容詞之詞性還原、NLTK不夠細緻,縮寫(ex. 無法處理 It 's)
- 目標:

```
went/ goes \rightarrow go
cars \rightarrow car
better \rightarrow good
```

文本前處理—斷詞(Segmentation)

先進行各種文本預處理,例如透過人工標記的方式保留完整片語、去除符號及stop words,使研究更精確

- 使用套件:NLTK
- 斷詞預處理:去除符號及stopwords後,在保留片語的前提下將句子斷成單詞
- 以 However, there are a lot of companies doing this!為例

處理順序

- 詞性還原後的句子: however, there be a lot of company do this!
- 去除符號及 stopwords: however there a lot of company do this
- 保留片語進行斷詞: however, there, a lot of, company, do, this
- 若不保留片語語意會不精準: however, there, a, lot, of, company, do, this



• Stop words 定義(Stanford): some extremely common words which would appear to be of little value in helping select documents matching a user need are excluded from the vocabulary entirely. These words are called *stop words*.

得到一串詞 的 list 以進 行後續分析

狀態分類(Label)—Good/Neutral/Bad

隨機亂數抽取不同法說會之段落,並以個人主觀之方式給予Good/Neutral/Bad之標記, 之後針對各字詞檢視是否在Good/Bad狀態差異顯著下具合理性,若為不具合理性之字 詞則反視原段落之該詞前文是否有否定詞,若有則改變該詞為non-____。

Good 範例字

Bad 範例字

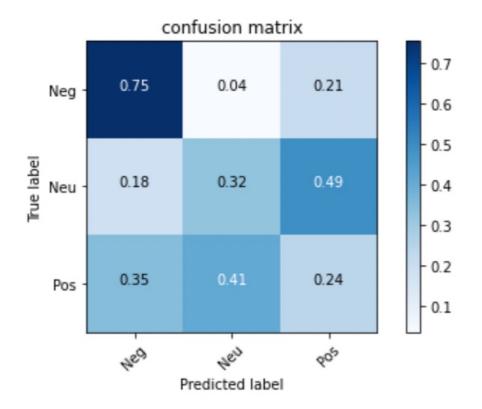
```
t1,p1 ,t2,p2= check_words_t_test_result('distortion')
t1,p1 ,t2,p2= check_words_t_test_result('enhancing')
print(f'good bad t-value :{t1}')
                                                    print(f'good bad t-value :{t1}')
print(f'good bad p-value :{p1}')
                                                    print(f'good bad p-value :{p1}')
print(f'good neu t-value :{t2}')
                                                    print(f'good neu t-value :{t2}')
print(f'good neu p-value :{p2}')
                                                    print(f'good neu p-value :{p2}')
good bad t-value :5.240565007
                                                    good bad t-value :-5.749282571
good bad p-value :0.000968667
                                                    good bad p-value :0.005226515
good neu t-value :2.922203127
                                                    good neu t-value :-4.082482905
good neu p-value :0.021574189
                                                    good neu p-value :0.076464126
```

BERT model (base-cased)

• 訓練集: 1250段(pos:539, neu:438, neg:273)

• Test: pos: 20/83, neu: 44/136, neg: 61/81

	precision	recall	f1-score	support	
Neg	0.53	0.75	0.62	81	
Neu	0.54	0.32	0.41	136	
Pos	0.19	0.24	0.21	83	
accuracy			0.42	300	
macro avg	0.42	0.44	0.41	300	
veighted avg	0.44	0.42	0.41	300	



投資組合回測

- 初始資金為30萬,平均持有當時費半30所有成分股
- 若模型判別文本分數情緒總和低於-0.25則該公司剔除於該季投資組合,直至下次法說會
- 若該公司已被排除在費半30指數之外,則剔除該公司於投資組合中
- 總文本數: 3081 (non-neg:2515, neg:566) · 2004/12/31 2022/06/01

1	Type	Content		
2	Total_Return	584.5297545		
3	Internal_Rate_Return	11.66782096		
4	Volatility	0.985392058		
5	Sharpe_Ratio	0.565496933		
6	Max_Drawdown	-0.332013864		
7	Max_Drawdown_Start	2011/2/17 00:00		
8	Max_Drawdown_End	2011/10/3 00:00		
9	Max_Drawdown_Continuos_Days	228 days 00:00:00		
10	Profit_Risk_Ratio	17.6055827		

1	Type	Content
2	Total_Return	603.660207
3	Internal_Rate_Return	11.84454862
4	Volatility	1.539003314
5	Sharpe_Ratio	0.438842248
6	Max_Drawdown	-0.689023588
7	Max_Drawdown_Start	2006/1/27 00:00
8	Max_Drawdown_End	2008/11/20 00:00
9	Max_Drawdown_Continuos_Days	1028 days 00:00:00
10	Profit_Risk_Ratio	8.761096397

• 投組各項數值回測

• 費半30各項數值回測



結論

• 該投組交易方式能降低波動度,提升夏普值

• 能反應產業實體經濟,然而不能完全反應總體經濟狀況

- 法說會屬於落後資訊,並不能完全避免跌勢
- 可以搭配其他量化資訊做參考,改進投組表現

改善目標

• 嘗試更多種類模型(XLNet、ELECTRA......), 並加入文本內對於 產業數值的情緒判別

• 加入更多其他量化數據一同參考,進行樣本外測試

• 擴增標註文本數量

• 嘗試不同投資交易及調整不同參數方式

最新投組





Thank You